

ỦY BAN NHÂN DÂN THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC SÀI GÒN
KHOA TOÁN- ỨNG DỤNG



BÀI BÁO CÁO

MÔN: KHAI PHÁ DỮ LIỆU

Đề tài: **PHÂN TÍCH KHÁM PHÁ DỮ LIỆU**

Giảng viên hướng dẫn : Đỗ Như Tài

Sinh viên thực hiện : Họ và tên

Mã số sinh viên

Phạm Ngọc Phương Uyên

3123580061

Trần Thu Hiền

3123580013

Nguyễn Châu Nhật Tường

3123580060

Lớp : DDU1231

Thành phố Hồ Chí Minh, tháng 10 năm 2025

LỜI CẢM ƠN

Trước tiên, nhóm sinh viên chúng em xin gửi lời cảm ơn chân thành và sâu sắc đến thầy Đỗ Như Tài – giảng viên phụ trách môn Khai phá dữ liệu, thầy đã tận tình giảng dạy, hướng dẫn và hỗ trợ chúng em xuyên suốt quá trình học tập cũng như trong quá trình thực hiện bài báo cáo này. Những kiến thức, định hướng và góp ý từ thầy là nền tảng quan trọng giúp nhóm chúng em hoàn thiện bài báo cáo một cách hiệu quả và thực tế hơn.

Chúng em cũng xin trân trọng cảm ơn toàn thể quý thầy cô Khoa Toán – Ứng dụng, đã tạo điều kiện thuận lợi về môi trường học tập, tài liệu và cơ sở vật chất để chúng em có thể phát huy khả năng nghiên cứu, rèn luyện tư duy và kỹ năng làm việc nhóm.

Bên cạnh đó, nhóm cũng xin ghi nhận và cảm ơn sự hỗ trợ, phối hợp chặt chẽ giữa các thành viên trong nhóm trong suốt thời gian làm việc. Mỗi thành viên đều có sự đóng góp tích cực về nội dung, kỹ thuật và hình thức trình bày, góp phần tạo nên một bài đồ án hoàn chỉnh như hiện tại.

Mặc dù đã nỗ lực rất nhiều trong quá trình thực hiện, nhưng với kiến thức và kinh nghiệm còn hạn chế, bài báo cáo khó tránh khỏi những thiếu sót. Nhóm rất mong nhận được sự góp ý, nhận xét quý báu từ thầy và các bạn để có thể tiếp tục hoàn thiện trong các đề tài, báo cáo sau này.

Một lần nữa, chúng em xin chân thành cảm ơn!

BẢNG PHÂN CHIA CÔNG VIỆC

Thứ tự	Họ và tên	Công việc phụ trách	Mức độ hoàn thành
1	Phạm Ngọc Phương Uyên	- Phụ trách nội dung xử lý và trực quan hóa dữ liệu - Hoàn thiện bài báo cáo	100%
2	Trần Thu Hiền	- Phụ trách nội dung thống kê mô tả	100%
3	Nguyễn Châu Nhật Tường	-Phụ trách nội dung phân tích đơn biến và hai biến	100%

MỤC LỤC

PHẦN I: THỐNG KÊ MÔ TẢ	6
1.1. ÔN TẬP LÝ THUYẾT.....	6
2.2. BÀI TẬP	9
Bài tập thực hành 1: Thực hiện thống kê mô tả trên tập dữ liệu về phân loại chất lượng rượu đỏ.	9
Bài tập thực hành 2: Thực hiện thống kê mô tả trên tập dữ liệu về bệnh tiểu đường.....	16
PHẦN II: XỬ LÝ VÀ TRỰC QUAN HÓA DỮ LIỆU	22
2.1. ÔN TẬP LÝ THUYẾT.....	22
2.2. BÀI TẬP	25
Bài tập thực hành 1: Thực hiện trực quan hóa dữ liệu trên tập dữ liệu về phân loại chất lượng rượu đỏ.	25
Bài tập thực hành 2:.....	30
Thực hiện trực quan hóa dữ liệu trên tập dữ liệu về bệnh tiểu đường.	30
Thực hiện EDA trên tập dữ liệu mua sắm tại siêu thị.	34
PHẦN III: PHÂN TÍCH ĐƠN BIẾN VÀ HAI BIẾN.....	39
3.1. ÔN TẬP LÝ THUYẾT.....	39
3.2. BÀI TẬP	43
Bài tập thực hành 1: Tìm hiểu các tính năng và cách sử dụng sản phẩm SweetViz áp dụng trên tập dữ liệu Marketing Campaign	43

Bài tập thực hành 2: Tìm hiểu các tính năng và cách sử dụng sản phẩm AutoViz áp dụng trên tập dữ liệu Marketing Campaign.....	54
--	----

PHẦN I: THỐNG KÊ MÔ TẢ

1.1. ÔN TẬP LÝ THUYẾT

- **Thống kê mô tả là gì? Nó khác gì với thống kê suy luận (inferential statistics)?**
 - **Thống kê mô tả:** Tóm tắt, tổ chức và trình bày các đặc điểm chính của *dữ liệu hiện có* để hiểu rõ hơn về chúng (Ví dụ: tính trung bình, phân bố).
 - **Thống kê suy luận:** Dùng dữ liệu *mẫu* để đưa ra kết luận, dự đoán hoặc khái quát hóa về *quần thể lớn hơn*.
 - **Khác biệt chính:** Mô tả *mô tả*, suy luận *khái quát hóa*.
- **Các thước đo thống kê mô tả chính (ví dụ: trung bình, trung vị, phương sai, độ lệch chuẩn) được sử dụng để làm gì? Trong trường hợp nào thì nên dùng trung vị thay vì trung bình?**
 - **Khuynh hướng trung tâm (mean, median, mode):** Chỉ ra giá trị "điển hình" của dữ liệu.
 - **Độ phân tán (variance, std dev, range, IQR):** Đo lường mức độ "lan rộng" của dữ liệu.
 - **Dùng trung vị thay trung bình:** Khi dữ liệu có **phân bố lệch** hoặc có **giá trị ngoại lai**, vì trung vị ít bị ảnh hưởng bởi các giá trị cực đoan hơn trung bình.
- **Làm thế nào để xác định phân bố của một tập dữ liệu? Các loại phân bố phổ biến là gì (ví dụ: phân bố chuẩn, lệch trái, lệch phải)?**
 - **Xác định phân bố:** Dùng biểu đồ trực quan (Histogram, Boxplot) hoặc chỉ số định lượng (Skewness, Kurtosis).

- **Phân bố phổ biến:**

Phân bố Chuẩn (Normal Distribution): Hình chuông, đối xứng (Mean = Median = Mode).

Phân bố Lệch phải (Right-Skewed): Đuôi kéo dài về bên phải (Mean > Median).

Phân bố Lệch trái (Left-Skewed): Đuôi kéo dài về bên trái (Mean < Median).

- **Độ lệch chuẩn và phạm vi (range) có ý nghĩa gì trong việc đánh giá sự phân tán của dữ liệu?**

- **Độ lệch chuẩn (SD):** Đo lường mức độ phân tán **trung bình** của các điểm dữ liệu so với giá trị trung bình. SD nhỏ = dữ liệu tập trung.
- **Phạm vi (Range):** Hiệu số giữa giá trị Max và Min, cho biết **tổng độ trải** của dữ liệu.
- **Ý nghĩa:** Cả hai đều đánh giá sự biến động, nhưng SD cung cấp thông tin chi tiết hơn quanh trung bình, còn Range nhạy cảm hơn với ngoại lai.

- **Sự khác biệt giữa các thước đo như Q1, Q2, Q3 trong biểu đồ hộp (boxplot) là gì?**

- **Q1 (Tứ phân vị 1 - 25th Percentile):** 25% dữ liệu nằm dưới giá trị này (cạnh dưới của hộp).
- **Q2 (Tứ phân vị 2 - 50th Percentile / Trung vị):** 50% dữ liệu nằm dưới giá trị này (đường kẻ trong hộp).

- **Q3 (Tứ phân vị 3 - 75th Percentile):** 75% dữ liệu nằm dưới giá trị này (cạnh trên của hộp).
 - **IQR (Q3 - Q1):** Đại diện cho 50% dữ liệu ở giữa.
- **Làm thế nào để xử lý giá trị thiếu (missing values) trước khi tính toán các chỉ số thống kê mô tả?**
- **Xác định:** Dùng `df.isnull().sum()` và kiểm tra các giá trị 0 không có ý nghĩa.
 - **Phương pháp xử lý:**
 - Loại bỏ:** Xóa dòng/cột chứa giá trị thiếu (khi số lượng ít hoặc cột không quan trọng).
 - Điền khuyết (Imputation):** Thay thế bằng trung bình, trung vị, yếu vị, hoặc sử dụng các mô hình dự đoán phức tạp hơn. Lựa chọn phụ thuộc vào ngữ cảnh và mức độ thiếu.
- **Cách đọc và diễn giải một biểu đồ histogram hoặc boxplot từ dữ liệu thực tế**
- **Histogram:**
 - Đọc:** Nhìn vào hình dạng (đối xứng, lệch), số đỉnh (một hay nhiều), tâm (giá trị phổ biến), và độ lan truyền (phạm vi).
 - Diễn giải:** "Phân bố của [biến] có vẻ [hình dạng], tập trung quanh [giá trị], với [độ lan truyền]."
 - **Boxplot:**

Đọc: Nhìn vào đường trung vị (Q2), chiều dài hộp (IQR từ Q1 đến Q3), chiều dài râu (whiskers), và các điểm ngoại lai.

Diễn giải: "Trung vị của [biến] là [giá trị]. 50% dữ liệu nằm trong khoảng từ [Q1] đến [Q3]. Có [số lượng] giá trị ngoại lai cho thấy [điểm bất thường]."

- **Khi gặp một tập dữ liệu có giá trị ngoại lai (outliers), bạn sẽ xử lý chúng như thế nào trước khi thực hiện thống kê mô tả?**

- **Xác định:** Sử dụng Boxplot, phương pháp IQR ($Q1 - 1.5 \cdot IQR$, $Q3 + 1.5 \cdot IQR$), hoặc Z-score.
- **Điều tra nguyên nhân:** Luôn cố gắng hiểu tại sao outliers xuất hiện (lỗi nhập liệu hay giá trị thật sự).
- **Chiến lược xử lý:**

Giữ lại: Nếu là giá trị thật và quan trọng (dùng trung vị cho mô tả).

Xóa: Nếu là lỗi hoặc quá cực đoan, làm sai lệch phân tích.

Chuyển đổi: Áp dụng logarit, căn bậc hai để giảm tác động.

Capping/Winsorization: Giới hạn giá trị outliers ở một ngưỡng nhất định.

2.2. BÀI TẬP

Bài tập thực hành 1: Thực hiện thống kê mô tả trên tập dữ liệu về phân loại chất lượng rượu đỏ.

**Nhiệm vụ 1: Khám phá dữ liệu phân loại chất lượng rượu đỏ.
phân loại chất lượng rượu đỏ.**

Tính mean, median, mode, variance, standard deviation, range, percentile, quartile, interquartile range (IQR) sử dụng thư viện numpy và stats trên tập dữ liệu

```
wine_data.head(5)

wine_data.dtypes

wine_data.shape
```

- Thống kê mô tả

```
column_to_analyze = wine_data["alcohol"]

print(f"\n--- Thống kê mô tả cho cột  
'{column_to_analyze.name}' ---")
```

--- Thống kê mô tả tổng quan (.describe()) ---

	fixed acidity	volatile acidity	citric acid	residual sugar \
count	1599.000000	1599.000000	1599.000000	1599.000000
mean	8.319637	0.527821	0.270976	2.538806
std	1.741096	0.179060	0.194801	1.409928
min	4.600000	0.120000	0.000000	0.900000
25%	7.100000	0.390000	0.090000	1.900000
50%	7.900000	0.520000	0.260000	2.200000
75%	9.200000	0.640000	0.420000	2.600000
max	15.900000	1.580000	1.000000	15.500000

	chlorides	free sulfur dioxide	total sulfur dioxide	density \
count	1599.000000	1599.000000	1599.000000	1599.000000
mean	0.087467	15.874922	46.467792	0.996747
std	0.047065	10.460157	32.895324	0.001887
min	0.012000	1.000000	6.000000	0.990070
25%	0.070000	7.000000	22.000000	0.995600
50%	0.079000	14.000000	38.000000	0.996750
75%	0.090000	21.000000	62.000000	0.997835
max	0.611000	72.000000	289.000000	1.003690

	pH	sulphates	alcohol	quality
count	1599.000000	1599.000000	1599.000000	1599.000000
mean	3.311113	0.658149	10.422983	5.636023
...				
25%	3.210000	0.550000	9.500000	5.000000
50%	3.310000	0.620000	10.200000	6.000000
75%	3.400000	0.730000	11.100000	6.000000
max	4.010000	2.000000	14.900000	8.000000

- Tính mean

```
data_mean = np.mean(column_to_analyze)

print(f"Giá trị trung bình (Mean) của
'{column_to_analyze.name}': {data_mean:.2f}")
```

Giá trị trung bình (Mean) của 'alcohol': 10.42

- Tính Median

```
data_median = np.median(column_to_analyze)
```

```
print(f"Giá trị trung vị (Median) của  
'{column_to_analyze.name}': {data_median:.2f}")
```

Giá trị trung vị (Median) của 'alcohol': 10.20

- Tính mode

```
data_mode_result = stats.mode(column_to_analyze,  
keepdims=True) # keepdims=True để tránh cảnh báo  
  
print(f"Giá trị yếu vị (Mode) của  
'{column_to_analyze.name}':  
{data_mode_result.mode[0]:.2f} (xuất hiện  
{data_mode_result.count[0]} lần)")
```

Giá trị yếu vị (Mode) của 'alcohol': 9.50 (xuất hiện 139 lần)

- Tính variance

```
data_variance = np.var(column_to_analyze)  
print(f"Phương sai (Variance) của  
'{column_to_analyze.name}': {data_variance:.2f}")
```

Phương sai (Variance) của 'alcohol': 1.13

- Tính Standard Deviation

```
data_sd = np.std(column_to_analyze)  
print(f"Độ lệch chuẩn (Standard Deviation) của  
'{column_to_analyze.name}': {data_sd:.2f}")
```

Độ lệch chuẩn (Standard Deviation) của 'alcohol': 1.07

- Tính max/min

```
data_max = np.max(column_to_analyze)  
data_min = np.min(column_to_analyze)  
print(f"Giá trị lớn nhất (Max) của  
'{column_to_analyze.name}': {data_max:.2f}")
```

```
print(f"Giá trị nhỏ nhất (Min) của  
'{column_to_analyze.name}': {data_min:.2f}")
```

Giá trị lớn nhất (Max) của 'alcohol': 14.90

Giá trị nhỏ nhất (Min) của 'alcohol': 8.40

- Tính percentile

```
data_percentile_60 = np.percentile(column_to_analyze,  
60)  
print(f"Phân vị thứ 60 (60th Percentile) của  
'{column_to_analyze.name}': {data_percentile_60:.2f}")  
  
data_quartile_75 = np.quantile(column_to_analyze, 0.75)  
print(f"Tứ phân vị thứ 3 (Q3 - 75th Percentile) của  
'{column_to_analyze.name}': {data_quartile_75:.2f}")
```

- Tính range

```
data_range = data_max - data_min  
print(f"Khoảng biến thiên (Range) của  
'{column_to_analyze.name}': {data_range:.2f}")
```

Khoảng biến thiên (Range) của 'alcohol': 6.50

- Tính IQR

```
data_IQR = stats.iqr(column_to_analyze)  
print(f"Khoảng Tứ phân vị (IQR) của  
'{column_to_analyze.name}': {data_IQR:.2f}")
```

Khoảng Tứ phân vị (IQR) của 'alcohol': 1.60

Nhiệm vụ 2: Khám phá và xử lý dữ liệu

```
wine_data.head()  
  
wine_data_duplicate = wine_data.drop_duplicates()
```

```
wine_data_after_drop_row_1 = wine_data.drop(labels=[1],
axis=0)

wine_data_after_drop_fixed_acidity =
wine_data.drop(labels=['fixed acidity'], axis=1)

wine_data['quality_category'] =
wine_data['quality'].replace(
    [3, 4, 5], 'low'
).replace(
    6, 'medium'
).replace(
    [7, 8], 'high'
)

wine_data['volatile_acidity_filled'] =
wine_data['volatile acidity'].fillna(0)

wine_data['alcohol_int'] =
wine_data['alcohol'].astype(int)

(wine_data.isnull().sum())
```

fixed acidity	0
volatile acidity	0
citric acid	0
residual sugar	0
chlorides	0
free sulfur dioxide	0
total sulfur dioxide	0
density	0
pH	0
sulphates	0
alcohol	0
quality	0
quality_category	0
volatile_acidity_filled	0
alcohol_int	0
dtype:	int64

Nhận xét Tổng quan về Bộ Dữ liệu Rượu Vang Đỏ

1. Kích thước và Cấu trúc Dữ liệu:

- Số lượng quan sát: 1599 mẫu rượu vang đỏ.
- Số lượng thuộc tính (Features): Có 12 thuộc tính hóa học đầu vào và 1 thuộc tính đầu ra (quality).

11 thuộc tính hóa học đầu vào là các biến số liên tục (ví dụ: fixed acidity, alcohol, pH,...).

1 thuộc tính đầu ra là quality, một biến số nguyên rời rạc biểu thị chất lượng rượu trên thang điểm từ 3 đến 8.

- Định dạng dữ liệu: Tất cả các thuộc tính đều ở định dạng số (float64 hoặc int64),

2. Chất lượng Dữ liệu:

- Giá trị thiếu (Missing Values):** Đây là một điểm mạnh lớn của bộ dữ liệu. Kết quả `wine_data.isnull().sum()` cho thấy **không có bất kỳ giá trị thiếu nào** trên tất cả các cột.
- Giá trị trùng lặp (Duplicate Values):** Thực hiện `drop_duplicates()`

3. Phân bố các thuộc tính:

- **Tính đa dạng:** Các chỉ số như độ lệch chuẩn và khoảng biến thiên (range) cho thấy sự đa dạng đáng kể trong các đặc tính hóa học của rượu
- **Xu hướng trung tâm và độ phân tán:**

alcohol (nồng độ cồn) là một ví dụ điển hình với mean (10.42) và median (10.20) gần nhau, cho thấy phân bố tương đối cân đối, có thể hơi lệch phải nhẹ. Mode của alcohol là 9.50.

Một số biến như chlorides, sulphates, residual sugar và total sulfur dioxide có giá trị lớn nhất (max) khá cao so với giá trị trung bình và Q3, điều này có thể gợi ý sự hiện diện của các **giá trị ngoại lai (outliers)**.

- **Biến mục tiêu quality:**

Chất lượng rượu chủ yếu tập trung ở mức **trung bình** (mode = 5 hoặc 6, mean = 5.64).

Phạm vi chất lượng từ 3 đến 8, không có rượu ở mức rất kém (1, 2) hoặc rất xuất sắc (9, 10). Điều này cho thấy tập dữ liệu có thể có sự **mất cân bằng lớp**

4. Tiền xử lý Dữ liệu: quality_category (low, medium, high) là một cách hiệu quả để chuyển đổi biến chất lượng rời rạc thành một biến phân loại

Bài tập thực hành 2: Thực hiện thống kê mô tả trên tập dữ liệu về bệnh tiểu đường.

Nhiệm vụ 1: Khám phá dữ liệu về bệnh tiểu đường

Tính mean, median, mode, variance, standard deviation, range, percentile, quartile, interquartile range (IQR) sử dụng thư viện numpy và stats trên tập dữ liệu

```
diabetes_data.head(5)
diabetes_data.dtypes
diabetes_data.shape
print("\n--- Thống kê mô tả tổng quan (.describe()) ---")
print(diabetes_data.describe())
```

--- Thống kê mô tả tổng quan (.describe()) ---

	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin \
count	768.000000	768.000000	768.000000	768.000000	768.000000
mean	3.845052	120.894531	69.105469	20.536458	79.799479
std	3.369578	31.972618	19.355807	15.952218	115.244002
min	0.000000	0.000000	0.000000	0.000000	0.000000
25%	1.000000	99.000000	62.000000	0.000000	0.000000
50%	3.000000	117.000000	72.000000	23.000000	30.500000
75%	6.000000	140.250000	80.000000	32.000000	127.250000
max	17.000000	199.000000	122.000000	99.000000	846.000000

	BMI	DiabetesPedigreeFunction	Age	Outcome
count	768.000000	768.000000	768.000000	768.000000
mean	31.992578	0.471876	33.240885	0.348958
std	7.884160	0.331329	11.760232	0.476951
min	0.000000	0.078000	21.000000	0.000000
25%	27.300000	0.243750	24.000000	0.000000
50%	32.000000	0.372500	29.000000	0.000000
75%	36.600000	0.626250	41.000000	1.000000
max	67.100000	2.420000	81.000000	1.000000

- Tính mean

```
selected_column = diabetes_data["Glucose"]

data_mean = np.mean(selected_column)
print(f"Giá trị trung bình (Mean) của
'{selected_column.name}': {data_mean:.2f}")
```

Giá trị trung bình (Mean) của 'Glucose': 120.89

- Tính median

```
data_median = np.median(selected_column)
print(f"Giá trị trung vị (Median) của
'{selected_column.name}': {data_median:.2f}")
```

Giá trị trung vị (Median) của 'Glucose': 117.00

- **Tính mode**

```
data_mode_result = stats.mode(selected_column,
keepdims=True)
print(f"Giá trị yếu vị (Mode) của
'{selected_column.name}': {data_mode_result.mode[0]:.2f}
(xuất hiện {data_mode_result.count[0]} lần)")
```

Giá trị yếu vị (Mode) của 'Glucose': 99.00 (xuất hiện 17 lần)

- **Tính variance**

```
data_variance = np.var(selected_column)
print(f"Phương sai (Variance) của
'{selected_column.name}': {data_variance:.2f}")
```

Phương sai (Variance) của 'Glucose': 1020.92

- **Tính Standard Deviation**

```
data_sd = np.std(selected_column)
print(f"Độ lệch chuẩn (Standard Deviation) của
'{selected_column.name}': {data_sd:.2f}")
```

Độ lệch chuẩn (Standard Deviation) của 'Glucose': 31.95

- **Tính max/min**

```
data_max = np.max(selected_column)
data_min = np.min(selected_column)
print(f"Giá trị lớn nhất (Max) của '{selected_column.name}':
{data_max:.2f}")
print(f"Giá trị nhỏ nhất (Min) của '{selected_column.name}':
{data_min:.2f}")
```

Giá trị lớn nhất (Max) của 'Glucose': 199.00

Giá trị nhỏ nhất (Min) của 'Glucose': 0.00

- **Tính range**

```
data_range = data_max - data_min
print(f"Khoảng biến thiên (Range) của
'{selected_column.name}': {data_range:.2f}")
```

Khoảng biến thiên (Range) của 'Glucose': 199.00

- Tính percentile

```
data_percentile_60 = np.percentile(selected_column, 60)
print(f"Phân vị thứ 60 (60th Percentile) của
'{selected_column.name}': {data_percentile_60:.2f}")
```

Phân vị thứ 60 (60th Percentile) của 'Glucose': 125.00

```
q1 = np.quantile(selected_column, 0.25)
q2 = np.quantile(selected_column, 0.50) # Tứ phân vị thứ
2 chính là trung vị
q3 = np.quantile(selected_column, 0.75)
print(f"Tứ phân vị thứ 1 (Q1 - 25th Percentile) của
'{selected_column.name}': {q1:.2f}")
print(f"Tứ phân vị thứ 2 (Q2 - 50th Percentile / Median)
của '{selected_column.name}': {q2:.2f}")
print(f"Tứ phân vị thứ 3 (Q3 - 75th Percentile) của
'{selected_column.name}': {q3:.2f}")
```

Tứ phân vị thứ 1 (Q1 - 25th Percentile) của 'Glucose': 99.00

Tứ phân vị thứ 2 (Q2 - 50th Percentile / Median) của 'Glucose': 117.00

Tứ phân vị thứ 3 (Q3 - 75th Percentile) của 'Glucose': 140.25

- Tính IQR

```
data_IQR = stats.iqr(selected_column)
print(f"Khoảng Tứ phân vị (IQR) của
'{selected_column.name}': {data_IQR:.2f}")
```

Khoảng Tứ phân vị (IQR) của 'Glucose': 41.25

Nhiệm vụ 2: Khám phá và xử lý dữ liệu

```
diabetes_data.head()

diabetes_data_duplicate = diabetes_data.drop_duplicates()

diabetes_data_after_drop_row_1 =
diabetes_data.drop(labels=[1], axis=0)

diabetes_data_after_drop_pregnancies =
diabetes_data.drop(labels=['Pregnancies'], axis=1)


diabetes_data['Outcome_category'] =
diabetes_data['Outcome'].replace(
    [0, 1], ['No Diabetes', 'Diabetes'])

diabetes_data['Insulin_filled'] =
diabetes_data['Insulin'].fillna(0)

diabetes_data['BMI_int'] =
diabetes_data['BMI'].astype(int)


diabetes_data.isnull().sum()

diabetes_data_withoutna = diabetes_data.dropna(how =
'any')

print(diabetes_data_withoutna.shape)
```

Pregnancies	0
Glucose	0
BloodPressure	0
SkinThickness	0
Insulin	0
BMI	0
DiabetesPedigreeFunction	0
Age	0
Outcome	0
Outcome_category	0
Insulin_filled	0
BMI_int	0
dtype: int64	

Nhận xét Tổng quan về Bộ Dữ liệu Bệnh Tiểu Đường

1. Kích thước và Cấu trúc Dữ liệu:

- Số lượng quan sát: 768 bệnh nhân.
- Số lượng thuộc tính (Features): Có 8 thuộc tính đầu vào (các chỉ số y tế) và 1 thuộc tính đầu ra (Outcome).

Thuộc tính đầu ra Outcome là một biến phân loại nhị phân (0 hoặc 1), biểu thị không mắc tiểu đường (0) hoặc mắc tiểu đường (1).

- Định dạng dữ liệu: Tất cả các thuộc tính đều ở định dạng số (float64 hoặc int64)

2. Chất lượng Dữ liệu:

Bộ dữ liệu này có **nhiều giá trị thiếu được mã hóa là 0** trong các cột Glucose, BloodPressure, SkinThickness, Insulin, và BMI.

Đây là một vấn đề nghiêm trọng cần được xử lý trước khi phân tích sâu hoặc xây dựng mô hình, ví dụ như thay thế các giá trị 0 không hợp lý bằng NaN và sau đó điền vào (impute) hoặc loại bỏ chúng

3. Phân bố thuộc tính:

Trung bình 0.348958. Điều này có nghĩa là khoảng **34.9%** số bệnh nhân trong tập dữ liệu mắc bệnh tiểu đường (Outcome = 1) và khoảng **65.1%** không mắc (Outcome = 0).

Đây là một trường hợp **mất cân bằng lớp (class imbalance)**. Lớp "không tiểu đường" chiếm đa số.

4. Tiền xử lý Dữ liệu:

Loại bỏ trùng lặp, xóa hàng/cột, tạo biến phân loại Outcome_category và biến đổi kiểu dữ liệu BMI_int, cũng như Insulin_filled (điền 0 vào giá trị thiếu).

PHẦN II: XỬ LÝ VÀ TRỰC QUAN HÓA DỮ LIỆU

2.1. ÔN TẬP LÝ THUYẾT

- **Trực quan hóa dữ liệu có vai trò gì trong phân tích dữ liệu? Tại sao nó quan trọng trong khám phá dữ liệu (EDA)?**

Trực quan hóa dữ liệu (Data Visualization) giúp **biểu diễn thông tin** dưới dạng **hình ảnh**, giúp con người dễ nhận biết xu hướng, mẫu (pattern), mối quan hệ và ngoại lệ (outliers) trong dữ liệu.

Trong khám phá dữ liệu (EDA – Exploratory Data Analysis), trực quan hóa giúp:

- Phát hiện phân phối dữ liệu (phân bố đều, lệch, có ngoại lệ...)
- Xác định mối tương quan giữa các biến.
- Kiểm tra giả định thống kê và định hướng lựa chọn mô hình phù hợp.

- **Các loại biểu đồ phổ biến (như histogram, scatter plot, boxplot, bar chart) được sử dụng trong các trường hợp nào?**

Biểu đồ	Dạng dữ liệu phù hợp	Mục đích chính
Histogram	Biến số liên tục	Thể hiện phân phối của dữ liệu
Boxplot	Biến số (phân nhóm theo danh mục)	Thể hiện trung vị, độ phân tán, ngoại lệ
Scatter plot	Hai biến số	Thể hiện mối tương quan giữa các biến
Bar chart	Biến phân loại (categorical)	So sánh tần suất hoặc giá trị trung bình giữa các nhóm
Line chart	Dữ liệu theo thời gian (time series)	Thể hiện xu hướng (trend) theo thời gian

Heatmap	Ma trận hoặc nhiều biến liên tục	Thể hiện mức độ tương quan hoặc cường độ
---------	----------------------------------	--

- **Làm thế nào để chọn loại biểu đồ phù hợp với đặc điểm của dữ liệu (ví dụ: dữ liệu phân loại, dữ liệu số, dữ liệu thời gian)?**

Loại dữ liệu	Loại biểu đồ
Phân loại (Categorical)	Bar chart, Pie chart
Số liên tục (Numerical)	Histogram, Boxplot, Scatter plot
Thời gian (Time series)	Line chart, Area chart
Tương quan giữa nhiều biến	Pairplot, Heatmap

- **Sự khác biệt giữa các thư viện trực quan hóa trong Python như Matplotlib, Seaborn và Plotly là gì?**

Đặc điểm	Matplotlib	Seaborn	Plotly
Mức độ cơ bản	Cơ bản, nền tảng cho các thư viện khác	Phát triển trên Matplotlib	Độc lập, hiện đại
Mục tiêu chính	Tạo biểu đồ tĩnh (static plots)	Tạo biểu đồ thống kê đẹp và dễ dùng	Tạo biểu đồ tương tác (interactive)
Ứng dụng phù hợp	Khi cần tùy chỉnh chi tiết biểu đồ	Khi cần biểu đồ thống kê, phân tích dữ liệu	Khi cần dashboard, web app, báo cáo tương tác
Định dạng đầu ra	PNG, PDF, SVG	PNG, PDF (thông qua Matplotlib)	HTML, PNG, PDF

- **Những nguyên tắc thiết kế nào cần tuân thủ để tạo ra một biểu đồ trực quan hóa dễ hiểu và hiệu quả?**

- Rõ ràng – Có tiêu đề, nhãn trục, chú giải.

- Đơn giản – Tránh rườm rà, chỉ thể hiện thông tin chính.
- Nhất quán – Giữ phong cách màu sắc, kích thước đồng đều.
- Tập trung vào thông điệp – Biểu đồ nên làm nổi bật insight chính.
- Chọn loại biểu đồ phù hợp với dữ liệu.

- **Làm thế nào để tạo một biểu đồ đơn giản như histogram hoặc bar chart bằng Matplotlib? Bạn có thể chia sẻ đoạn code mẫu không?**

Matplotlib là thư viện trực quan hóa dữ liệu cơ bản và mạnh mẽ nhất trong Python, cho phép tạo nhiều loại biểu đồ khác nhau như histogram, bar chart, scatter plot, line chart, v.v.

Để tạo biểu đồ, ta thường làm theo các bước chính sau:

1. Import thư viện Matplotlib.
2. Chuẩn bị dữ liệu (thường là dạng danh sách, mảng NumPy, hoặc DataFrame của Pandas).
3. Gọi hàm vẽ biểu đồ phù hợp (plt.hist() cho histogram, plt.bar() cho bar chart).
4. Thêm tiêu đề, nhãn trục, chú thích nếu cần.
5. Hiển thị hoặc lưu biểu đồ.

Code- Biểu đồ Histogram

```
import matplotlib.pyplot as plt
import numpy as np

# Tạo dữ liệu ngẫu nhiên (phân phối chuẩn)
data = np.random.normal(0, 1, 200)

# Vẽ histogram
plt.hist(data, bins=15, color='skyblue',
edgecolor='black')
plt.title("Histogram - Phân phối dữ liệu ngẫu nhiên")
plt.xlabel("Giá trị")
plt.ylabel("Tần suất")
plt.show()
```

Code- Biểu đồ Bar Chart

```
import matplotlib.pyplot as plt

# Tạo dữ liệu mẫu
categories = ['A', 'B', 'C', 'D']
values = [23, 45, 12, 36]

# Vẽ bar chart
plt.bar(categories, values, color='orange')
plt.title("Bar Chart - So sánh giữa các nhóm")
plt.xlabel("Nhóm")
plt.ylabel("Giá trị")
plt.show()
```

- **Làm thế nào để xuất biểu đồ từ Python ra các định dạng như PNG, PDF hoặc HTML để sử dụng trong báo cáo?**

```
# Lưu biểu đồ dưới dạng PNG
plt.savefig("bieu_do.png", dpi=300)

# Lưu dưới dạng PDF
plt.savefig("bieu_do.pdf")

# Với Plotly (biểu đồ tương tác)
import plotly.express as px
fig = px.bar(data, x='Category', y='Value', title='Bar Chart tương tác')
fig.write_html("bieu_do.html") # Xuất ra file HTML
fig.show()
```

2.2. BÀI TẬP

Bài tập thực hành 1: Thực hiện trực quan hóa dữ liệu trên tập dữ liệu về phân loại chất lượng rượu đỏ.

1. Chuẩn bị dữ liệu cho trực quan hóa dữ liệu

```
import pandas as pd

# Đọc dữ liệu
wine_data = pd.read_csv("winequality-red.csv",
sep=",")

# Giữ các cột quan trọng
```

```
wine_data = wine_data[['alcohol', 'pH', 'sulphates',
'quality']]

# Tạo biến mới: tỷ lệ alcohol trên pH
wine_data['Alcohol_per_pH'] = wine_data['alcohol'] /
wine_data['pH']

# Kiểm tra
print(wine_data.head())
```

2. Trực quan hóa dữ liệu với thư viện Matplotlib

```
import matplotlib.pyplot as plt

# Sắp xếp theo độ cồn (alcohol) giảm dần
wine_sorted = wine_data.sort_values('alcohol',
ascending=False)

# Case 1: Basic
plt.figure(figsize=(12,6))
x = range(10)
y = wine_sorted['alcohol'].head(10)
plt.bar(x, y)
plt.show()

# Case 2: Advanced
plt.figure(figsize=(12,6))
plt.bar(x, y)

plt.title('Top 10 wines with highest alcohol',
fontsize=15)


plt.xlabel('Wine index', fontsize=12)
plt.ylabel('Alcohol content', fontsize=12)
plt.show()

# Case 3: So sánh nhiều góc nhìn
fig, ax = plt.subplots(figsize=(40,18))
x = range(10)
```

```

y = wine_sorted['alcohol'].head(10)
y1 = wine_sorted['Alcohol_per_pH'].head(10)
plt.subplot(1,2,1)
plt.bar(x, y)
plt.ylabel('Alcohol content', fontsize=25)
plt.title('Top 10 wines with highest alcohol',
          fontsize=25)
plt.subplot(1,2,2)
plt.bar(x, y1)
plt.ylabel('Alcohol per pH', fontsize=25)
plt.title('Top 10 wines with highest Alcohol/pH
ratio', fontsize=25)
plt.show()

```



Hình 2.1 - Ảnh biểu đồ của thư viện Matplotlib

3. Trực quan hóa dữ liệu với thư viện Seaborn

```

import seaborn as sns
# Case 1: Basic
plt.figure(figsize=(12,6))
data = wine_sorted.head(10)
sns.barplot(data=data, x=data.index, y='alcohol')

```

```

plt.show()


# Case 2: Advanced
plt.figure(figsize=(12,6))
data = wine_sorted.head(10)
ax = sns.barplot(data=data, x=data.index,
y='alcohol')
ax.set_xlabel('Wine index', fontsize=15)
ax.set_ylabel('Alcohol content', fontsize=15)
ax.set_title('Top 10 wines with highest alcohol',
fontsize=20)
plt.show()

# Case 3: Nhiều góc nhìn
fig, ax = plt.subplots(1, 2, figsize=(40,18))
data = wine_sorted.head(10)
sns.set(font_scale=3)

# Biểu đồ 1
ax1 = sns.barplot(data=data, x=data.index,
y='alcohol', ax=ax[0])
ax1.set_title('Top 10 wines with highest alcohol')

# Biểu đồ 2
ax2 = sns.barplot(data=data, x=data.index,
y='Alcohol_per_pH', ax=ax[1])
ax2.set_title('Top 10 wines with highest Alcohol/pH
ratio')
plt.show()

```



Hình 2.2 - Ảnh biểu đồ của thư viện Seaborn

Nhận xét tổng quan về phân loại chất lượng rượu đỏ.

- Biểu đồ Top 10 Alcohol:**

Tất cả các biểu đồ đều cho thấy một vài loại rượu nổi bật (như mẫu ID 652) có độ cồn rất cao, xấp xỉ 15%.

Các mẫu còn lại dao động trong khoảng 13–14%, thể hiện sự đồng đều về độ mạnh giữa các loại rượu.

- Biểu đồ Top 10 Alcohol/pH:**

Tỉ lệ dao động khoảng 3–5, trong đó một mẫu (cũng là ID 652) nổi bật rõ rệt với giá trị gần 5.

Điều này cho thấy độ pH thấp (rượu chua hơn) thường đi kèm hàm lượng cồn cao, phản ánh mối tương quan dương giữa hai yếu tố này.

Từ góc nhìn hóa học, đây là chỉ dấu của rượu mạnh, vị gắt, ít acid tự do trung hòa.

Bài tập thực hành 2:

Thực hiện trực quan hóa dữ liệu trên tập dữ liệu về bệnh tiểu đường.

1. Chuẩn bị dữ liệu cho trực quan hóa dữ liệu

```
# Chuẩn bị dữ liệu
import pandas as pd

# Đọc dữ liệu
data = pd.read_csv("pima-indians-diabetes.csv")

# Xem 5 dòng đầu
print(data.head())

# Tạo biến mới tương tự "PriceperSqM"
data['GlucosePerBMI'] = data['Glucose'] / data['BMI']

# Gom nhóm theo tuổi trung bình để trực quan hóa
data_sorted = data.sort_values('Glucose', ascending=False)

# Xem dữ liệu sau xử lý
data_sorted.head()
```

2. Trực quan hóa dữ liệu với thư viện Matplotlib

```
# Trực quan hóa dữ liệu với Matplotlib
import matplotlib.pyplot as plt

# Lấy top 10 theo Glucose
top10 = data_sorted[:10]

# Case 1: Basic
plt.figure(figsize=(12, 6))

x = top10['Age']
y = top10['Glucose']

plt.bar(x, y)
```

```


plt.title('Top 10 người có mức Glucose cao nhất
(Matplotlib - Basic)')
plt.xlabel('Age')
plt.ylabel('Glucose Level')
plt.show()

# Case 2: Advanced 1
plt.figure(figsize=(12,6))
plt.bar(x, y, color='skyblue')
plt.title('Top 10 người có mức Glucose cao nhất',
fontsize=15)
plt.xlabel('Age', fontsize=12)
plt.ylabel('Glucose level', fontsize=12)
plt.xticks(fontsize=10)
plt.yticks(fontsize=10)
plt.show()

# Case 3: Advanced 2 (2 biểu đồ cạnh nhau)
fig, ax = plt.subplots(figsize=(20,8))
y1 = top10['GlucosePerBMI']
plt.subplot(1,2,1)
plt.bar(x, y, color='orange')
plt.title('Top 10 người có Glucose cao nhất', fontsize=18)
plt.xlabel('Age')
plt.ylabel('Glucose')
plt.subplot(1,2,2)
plt.bar(x, y1, color='green')
plt.title('Top 10 người có Glucose/BMI cao nhất',
fontsize=18)
plt.xlabel('Age')
plt.ylabel('Glucose per BMI')

```

```
plt.show()
```



Hình 2.3 - Ảnh biểu đồ của thư viện Matplotlib

3. Trực quan hóa dữ liệu với thư viện Seaborn

```
# Trực quan hóa dữ liệu với Seaborn
import seaborn as sns

# Case 1: Basic
plt.figure(figsize=(12,6))
sns.barplot(data=top10, x='Age', y='Glucose')
plt.title('Top 10 Glucose (Seaborn Basic)')
plt.show()

# Case 2: Advanced 1
plt.figure(figsize=(12,6))
ax = sns.barplot(data=top10, x='Age', y='Glucose',
color='coral')
ax.set_xlabel('Age', fontsize=15)
ax.set_ylabel('Glucose Level', fontsize=15)
ax.set_title('Top 10 người có Glucose cao nhất',
fontsize=20)
plt.show()


# Case 3: Multiple perspectives
fig, ax = plt.subplots(1, 2, figsize=(20,8))
sns.set(font_scale=1.5)

sns.barplot(data=top10, x='Age', y='Glucose', ax=ax[0],
color='skyblue')
```

```
ax[0].set_title('Glucose theo tuổi')

sns.barplot(data=top10, x='Age', y='GlucosePerBMI',
ax=ax[1], color='limegreen')
ax[1].set_title('Glucose/BMI theo tuổi')

plt.show()
```



Hình 2.4 - Ảnh biểu đồ của thư viện Seaborn

Nhận xét tổng quan tập dữ liệu về bệnh tiểu đường

- **Biểu đồ Top 10 Glucose**

Các biểu đồ cho thấy một vài cá nhân nổi bật có mức Glucose cao vượt trội so với phần còn lại, dao động khoảng 160–170 mg/dL.

Nhóm còn lại có giá trị Glucose trong khoảng 130–150 mg/dL, thể hiện mức độ đồng đều tương đối giữa những người có chỉ số cao.

Có thể kết luận rằng phần lớn người trong tập dữ liệu có mức Glucose cao nhưng không quá chênh lệch, chỉ một vài trường hợp thật sự vượt trội, biểu thị nguy cơ rối loạn đường huyết hoặc tiểu đường tiềm ẩn.

- **Biểu đồ Top 10 Glucose/BMI**

Tỷ lệ Glucose/BMI dao động trong khoảng 4–6, trong đó **một vài cá nhân nổi bật có giá trị gần 6**, cao hơn hẳn phần còn lại.

Điều này cho thấy **mức Glucose cao bất thường** so với **trọng lượng cơ thể**, tức là **nguy cơ tiểu đường độc lập** với chỉ số BMI (không chỉ do béo phì).

- **Thực hiện EDA trên tập dữ liệu mua sắm tại siêu thị.**

1. Chuẩn bị dữ liệu cho trực quan hóa dữ liệu

```
# Chuẩn bị dữ liệu cho trực quan hóa
import pandas as pd

# Đọc file CSV
data = pd.read_csv("Online Retail.csv",
encoding='ISO-8859-1')

# Xem 5 dòng đầu
print("5 dòng đầu dữ liệu:")
print(data.head())

# Loại bỏ dòng bị thiếu CustomerID hoặc
UnitPrice/Quantity âm
data = data.dropna(subset=['CustomerID'])
data = data[data['Quantity'] > 0]
data = data[data['UnitPrice'] > 0]

# Tạo biến mới: Tổng tiền = Quantity * UnitPrice
data['TotalPrice'] = data['Quantity'] *
data['UnitPrice']

# Gom nhóm theo quốc gia để xem tổng doanh thu theo
từng nước
country_sales = data.groupby('Country',
as_index=False) ['TotalPrice'].sum()

# Sắp xếp giảm dần theo tổng doanh thu
country_sales_sorted =
country_sales.sort_values('TotalPrice',
ascending=False)

print("\nTop 5 quốc gia có doanh thu cao nhất:")
print(country_sales_sorted.head())
```

2. Trực quan hóa dữ liệu với thư viện Matplotlib

```
# Trực quan hóa dữ liệu với thư viện Matplotlib
import matplotlib.pyplot as plt
```

```

# Lấy top 10 quốc gia có doanh thu cao nhất
top10 = country_sales_sorted.head(10)

# Case 1: Basic
plt.figure(figsize=(12,6))
plt.bar(top10['Country'], top10['TotalPrice'])
plt.title('Top 10 quốc gia có doanh thu cao nhất
(Basic)')
plt.xlabel('Quốc gia')
plt.ylabel('Tổng doanh thu')
plt.show()


# Case 2: Advanced 1
plt.figure(figsize=(12,6))
plt.bar(top10['Country'], top10['TotalPrice'],
color='orange')
plt.title('Top 10 quốc gia có doanh thu cao nhất',
fontsize=15)
plt.xlabel('Quốc gia', fontsize=12)
plt.ylabel('Tổng doanh thu (GBP)', fontsize=12)
plt.xticks(rotation=45, fontsize=10)
plt.yticks(fontsize=10)
plt.show()

# Case 3: Advanced 2 (so sánh tổng và trung bình)
country_avg = data.groupby('Country',
as_index=False)['UnitPrice'].mean()
merged = pd.merge(country_sales_sorted, country_avg,
on='Country')
top10_merged = merged.head(10)
fig, ax = plt.subplots(figsize=(20,8))
plt.subplot(1,2,1)
plt.bar(top10_merged['Country'],
top10_merged['TotalPrice'], color='skyblue')
plt.title('Top 10 quốc gia có tổng doanh thu cao
nhất', fontsize=18)
plt.xlabel('Quốc gia')
plt.ylabel('Tổng doanh thu')
plt.xticks(rotation=45)

plt.subplot(1,2,2)
plt.bar(top10_merged['Country'],
top10_merged['UnitPrice'], color='lightgreen')

```

```
plt.title('Top 10 quốc gia có giá trung bình cao nhất', fontsize=18)
plt.xlabel('Quốc gia')
plt.ylabel('Giá trung bình')
plt.xticks(rotation=45)
plt.show()
```



Hình 2.5 - Ảnh biểu đồ của thư viện Matplotlib

3. Trực quan hóa dữ liệu với thư viện Seaborn

```
# Trực quan hóa dữ liệu với thư viện Seaborn
import seaborn as sns

# Case 1: Basic
plt.figure(figsize=(12,6))
sns.barplot(data=top10, x='Country', y='TotalPrice')
plt.title('Top 10 quốc gia có doanh thu cao nhất (Seaborn Basic)')
plt.xticks(rotation=45)
plt.show()

# Case 2: Advanced 1
plt.figure(figsize=(12,6))
ax = sns.barplot(data=top10, x='Country', y='TotalPrice', color='coral')
ax.set_xlabel('Quốc gia', fontsize=15)
ax.set_ylabel('Tổng doanh thu (GBP)', fontsize=15)
ax.set_title('Top 10 quốc gia có doanh thu cao nhất', fontsize=20)
```


```
plt.xticks(rotation=45)
plt.show()

# Case 3: Multiple perspectives
fig, ax = plt.subplots(1, 2, figsize=(20,8))
sns.set(font_scale=1.3)

# Biểu đồ 1: Tổng doanh thu
sns.barplot(data=top10_merged, x='Country',
y='TotalPrice', ax=ax[0], color='skyblue')
ax[0].set_title('Tổng doanh thu theo quốc gia')

# Biểu đồ 2: Giá trung bình
sns.barplot(data=top10_merged, x='Country',
y='UnitPrice', ax=ax[1], color='limegreen')
ax[1].set_title('Giá trung bình theo quốc gia')

plt.setp(ax[0].get_xticklabels(), rotation=45)
plt.setp(ax[1].get_xticklabels(), rotation=45)
plt.tight_layout()
plt.show()
```



Hình 2.6 - Ảnh biểu đồ của thư viện Seaborn

Nhận xét tổng quan về dữ liệu mua sắm tại siêu thị

- Biểu đồ tổng doanh thu theo quốc gia

Biểu đồ cho thấy sự chênh lệch doanh thu rất lớn giữa các quốc gia.

Trong đó, Vương quốc Anh (United Kingdom) chiếm doanh thu vượt trội, đạt hơn 7 triệu, cao gấp nhiều lần so với các quốc gia còn lại.

Các nước như Netherlands, EIRE, Germany, France chỉ đóng góp một phần nhỏ, gần như không đáng kể so với tổng thể.

Điều này cho thấy thị trường chính tập trung tại Anh, phản ánh mức độ phụ thuộc doanh thu cao vào một khu vực duy nhất.

- **Biểu đồ giá trung bình theo quốc gia**

Giá trung bình (Unit Price) giữa các quốc gia không chênh lệch nhiều, dao động trong khoảng 2.5 – 4.5.

EIRE và France có mức giá trung bình cao nhất (~4.4–4.5), trong khi Netherlands và United Kingdom có giá thấp hơn.

Sự khác biệt nhẹ này cho thấy mức giá sản phẩm tương đối ổn định giữa các thị trường, không chịu tác động lớn bởi vị trí địa lý.

Tuy nhiên, nếu kết hợp với biểu đồ doanh thu, ta nhận thấy Anh quốc có doanh thu cao dù giá thấp, chứng tỏ số lượng hàng bán ra lớn, là yếu tố chính tạo nên tổng doanh thu vượt trội.

PHẦN III: PHÂN TÍCH ĐƠN BIẾN VÀ HAI BIẾN

3.1. ÔN TẬP LÝ THUYẾT

- **Phân tích đơn biến (univariate analysis) là gì? Nó khác gì với phân tích hai biến (bivariate analysis) trong khám phá dữ liệu?**

Phân tích đơn biến (Univariate Analysis) là phân tích tập trung vào một biến duy nhất tại một thời điểm, nhằm mô tả và tóm tắt đặc điểm của biến đó.

Mục tiêu chính là hiểu rõ phân bố, xu hướng trung tâm, độ biến thiên và các giá trị ngoại lai của biến đó.

Ví dụ: phân tích cột “tuổi” của khách hàng để xem độ tuổi trung bình, độ lệch chuẩn, phân bố tuổi.

Phân tích hai biến (Bivariate Analysis) là quá trình kiểm tra mối quan hệ hoặc sự tương tác giữa hai biến cùng một lúc.

Mục tiêu là tìm hiểu xem hai biến đó có tương quan với nhau hay không, và nếu có thì mối quan hệ đó mạnh đến mức nào và theo hướng nào.

Ví dụ: Phân tích mối quan hệ giữa tuổi và thu nhập, hoặc giữa số giờ học và điểm thi.

Đặc điểm	Phân tích Đơn biến (Univariate)	Phân tích Hai biến (Bivariate)
Số lượng biến	Một (1) biến	Hai (2) biến
Mục tiêu chính	Hiểu sự phân bố, xu hướng trung tâm, và sự phân tán (đánh giá chất lượng dữ liệu).	Khám phá mối quan hệ, tương quan, và tương tác giữa hai biến.
Kỹ thuật thống kê	Trung bình, Trung vị, Độ lệch chuẩn, Tần suất.	Hiệp biến, Tương quan, Bảng chéo, ANOVA.
Biểu đồ tiêu chuẩn	Histogram, Boxplot, Bar Chart, PieChart.	Scatter Plot, Heatmap, Boxplot/Violin Plot

- **Các thước đo thống kê nào thường được sử dụng trong phân tích đơn biến (ví dụ: trung bình, trung vị, mode, độ lệch chuẩn)?**
 - **Trung vị (Mean):** Là thước đo xu hướng trung tâm phổ biến nhất, phù hợp nhất khi dữ liệu phân bố đối xứng hoặc phân bố chuẩn. Nó được tính bằng tổng các giá trị chia cho số lượng quan sát.
 - **Trung vị (Median):** Là giá trị nằm ở chính giữa của tập dữ liệu đã sắp xếp. Trung vị chính là Tứ phân vị thứ hai (Q2) trong biểu đồ hộp (Boxplot).
 - **Mode (Yếu vị):** Là giá trị xuất hiện thường xuyên nhất. Thường được sử dụng cho dữ liệu phân loại hoặc rời rạc.
 - **Độ lệch chuẩn (Standard Deviation):** Đo lường mức độ phân tán của dữ liệu.
 - **Phạm vi (Range):** Khoảng cách giữa giá trị lớn nhất (Maximum) và giá trị nhỏ nhất (Minimum). Phạm vi cung cấp cái nhìn nhanh về sự lan truyền nhưng lại cực kỳ nhạy cảm với ngoại lai.
 - **Phương sai (Variance):** Đo lường mức độ phân tán của các điểm dữ liệu xung quanh giá trị trung bình.
 - **Độ lệch chuẩn (Standard Deviation - SD):** SD là căn bậc hai của Phương sai (Variance). SD có ý nghĩa quan trọng vì nó mô tả mức độ phân tán trung bình của các điểm dữ liệu xung quanh giá trị trung bình, và điều này được thực hiện bằng cách sử dụng cùng đơn vị với dữ liệu gốc, giúp việc diễn giải trở nên trực quan hơn.
 - **Phạm vi Liên Tứ phân vị (Interquartile Range - IQR):** Là khoảng cách giữa Q3 (75th percentile) và Q1 (25th percentile). IQR bao gồm 50% dữ liệu trung tâm và không bị ảnh hưởng bởi các giá trị ngoại lai ở hai đầu, khiến nó trở thành thước đo phân tán có tính ổn định cao (robust) đối với dữ liệu bị lệch.
- **Trong phân tích hai biến, làm thế nào để xác định mối quan hệ giữa hai biến (ví dụ: tương quan, nhân quả)?**
 - **Đối với biến số - biến số:**

Hệ số tương quan (Correlation coefficient) – đo mức độ và chiều hướng mối liên hệ.

Biểu đồ scatter plot – kiểm tra mối quan hệ tuyến tính hoặc phi tuyến.

- **Đối với biến số - biến phân loại:**

Dùng boxplot, violin plot, hoặc ANOVA test để xem sự khác biệt giữa các nhóm.

- **Đối với biến phân loại - phân loại:**

Dùng bảng chéo (crosstab), biểu đồ cột nhóm, hoặc kiểm định Chi-square.

- **Sự khác biệt giữa tương quan (correlation) và hiệp biến (covariance) trong phân tích hai biến là gì?**

Đặc điểm	Hiệp biến (Covariance)	Tương quan (Correlation)
Ý nghĩa	Đo mức độ hai biến thay đổi cùng nhau	Đo mức độ và chiều hướng mối liên hệ tuyến tính
Đơn vị đo	Phụ thuộc vào đơn vị gốc của biến	Không có đơn vị (chuẩn hóa trong $[-1, 1]$)
Phạm vi	Có thể lớn hoặc nhỏ tùy đơn vị	$-1 \leq r \leq 1$

- **Khi nào nên sử dụng biểu đồ trực quan hóa trong phân tích đơn biến so với phân tích hai biến?**

Loại phân tích	Biểu đồ thường dùng	Mục đích
Đơn biến (1 biến)	Histogram, Boxplot, Bar chart	Xem phân bố, outlier, tần suất
Hai biến (2 biến)	Scatter plot, Heatmap, Boxplot, Violin plot	Xem mối quan hệ, tương quan

- **Đoạn code mẫu để tạo biểu đồ scatter plot hoặc heatmap để phân tích mối quan hệ giữa hai biến?**

Code – Scatter plot

```
import matplotlib.pyplot as plt
import seaborn as sns
import pandas as pd

# Ví dụ dataset
df = pd.DataFrame({
    "X": [1, 2, 3, 4, 5, 6, 7],
    "Y": [2, 4, 5, 4, 6, 7, 9]
})

# Scatter plot
plt.figure(figsize=(6,4))
sns.scatterplot(x="X", y="Y", data=df, color="blue")
plt.title("Scatter Plot: Mối quan hệ giữa X và Y")
plt.xlabel("X")
plt.ylabel("Y")
plt.show()
```

Code – Heatmap

```
# Tính toán hệ số tương quan
corr = df.corr()

# Heatmap
plt.figure(figsize=(5,4))
sns.heatmap(corr, annot=True, cmap="coolwarm",
            fmt=".2f")
plt.title("Heatmap hệ số tương quan")
plt.show()
```

- **Làm thế nào để trực quan hóa mối quan hệ giữa một biến số và một biến phân loại bằng biểu đồ boxplot hoặc violin plot trong Python?**

Code - Box plot

```
import seaborn as sns
import matplotlib.pyplot as plt
import pandas as pd

# Ví dụ dataset
df = pd.DataFrame({
    "Nhóm": ["A", "A", "B", "B", "C", "C", "C"],
    "Điểm": [7, 8, 6, 9, 5, 6, 7]
})

# Vẽ boxplot
plt.figure(figsize=(6,4))
sns.boxplot(x="Nhóm", y="Điểm", data=df, palette="Set2")
plt.title("Boxplot: Mối quan hệ giữa Nhóm (phân loại) và Điểm (số)")
plt.show()
```

Code - Violin plot

```
plt.figure(figsize=(6,4))
sns.violinplot(x="Nhóm", y="Điểm", data=df,
inner="quartile", palette="Set3")
plt.title("Violin Plot: Phân phối điểm theo từng Nhóm")
plt.show()
```

3.2. BÀI TẬP


Bài tập thực hành 1: Tìm hiểu các tính năng và cách sử dụng sản phẩm SweetViz áp dụng trên tập dữ liệu Marketing Campaign

- **B1: Cài đặt thư viện sweetViz**
- **B2: Sử dụng sweetviz cho tập dữ liệu marketing_campaign.csv.**


B2.1: Báo cáo tổng quát tất cả các biến


```
import pandas as pd import sweetviz as sv # Đọc dữ liệu
marketcp_data =
pd.read_csv('/content/marketing_campaign.csv', sep='\t') #
Tạo báo cáo cho tất cả các biến report =
sv.analyze(marketcp_data)
report.show_html("marketcp_sweetviz.html")
```

Kết quả:




- Số hàng (ROW): 2240.
- Tổng số biến (FEATURES): 29 (trong đó có 15 biến loại numeric, 13 biến loại categorical, 1 biến loại text).
- Không có bản ghi trùng lặp (DUPLICATES = 0).
- Dung lượng Ram: 850,4 kb









- Những biểu đồ trên là các biến/cột đã được sweetviz thống kê, bên cạnh mỗi cột đều có 3 số liệu chính:
 - VALUES: Tổng số giá trị quan sát trong cột đó, trong hình 28 biểu đồ có VALUES 2240 (100%) nghĩa là có đủ dữ liệu cho 2.240 dòng, và 1 biểu đồ Income có VALUES 2216 (99%) nghĩa là biểu đồ này chỉ có dữ liệu cho 2216 dòng.
 - MISSING: Tỷ lệ giá trị bị thiếu (missing values), biểu đồ Income có MISSING: 24 (1%) nghĩa là có 24 dòng bị thiếu giá trị và tỷ lệ giá trị bị thiếu là 1%.
 - DISTINCT: Số lượng giá trị khác nhau trong cột đó (tức là độ đa dạng). Ví dụ: biểu đồ cột ID có DISTINCT: 2240 (100%) cho thấy mỗi dòng là duy nhất.

- Với những cột có loại giá trị là numeric thì sweetviz sẽ tiếp tục tính toán các thống kê:

- MAX: giá trị lớn nhất trong cột.
- RANGE: Là hiệu giữa max và min và cho biết độ rộng trải giá trị.
- 95%: Là giá trị mà 95% dữ liệu nằm bên dưới nó.
- IQR: Là hiệu giữa Q3 và Q1, dùng để đo mức độ phân tán trung tâm của dữ liệu (ổn định hơn STD vì ít bị ảnh hưởng bởi ngoại lai).
- Q3: Là phân vị thứ 75% của dữ liệu (còn gọi là “tứ phân vị thứ 3”).
- STD: Cho biết dữ liệu dao động bao nhiêu quanh giá trị trung bình.
- AVG: Là trung bình cộng của tất cả giá trị.
- VAR: Là bình phương của độ lệch chuẩn dùng để đo mức độ biến động của dữ liệu.
- MEDIA: Là giá trị ở giữa khi sắp xếp dữ liệu theo thứ tự tăng dần.
- Q1: Là phân vị thứ 25% của dữ liệu tức là 25% dữ liệu nhỏ hơn hoặc bằng giá trị này.
- KURT: Đo hình dạng đỉnh phân phối:

Nếu $KURT > 3 \rightarrow$ đỉnh nhọn, tập trung nhiều quanh trung bình.


Nếu $KURT < 3 \rightarrow$ đỉnh bẹt, dữ liệu trải đều.

- 5%: Giá trị mà 5% dữ liệu nhỏ hơn hoặc bằng nó, dùng để phát hiện giá trị thấp bất thường(outlier).
- SKEW: Đo mức độ lệch về bên trái hoặc phải của phân phối:

$SKEW > 0 \rightarrow$ lệch phải (phần đuôi kéo dài bên phải).

$SKEW < 0 \rightarrow$ lệch trái.

- MIN: Giá trị nhỏ nhất trong cột.
- SUM: Tổng cộng tất cả giá trị của cột.



Khi bấm vào nút “ASSOCIATIONS” sẽ hiện ra ma trận tương quan giữa các biến số và hệ số liên hệ giữa các biến phân loại:

- Màu xanh đậm: tương quan dương cao.

- Màu đỏ đậm: tương quan âm cao.
- Số trong ô: hệ số tương quan Pearson hoặc hệ số bất định.


B2.2: Báo cáo phân tích, tương quan biến mục tiêu "Response".

Mối tương quan và mối liên hệ giữa biến mục tiêu **"Response"** (phản hồi chiến dịch) với các cột dữ liệu khác.


```
import pandas as pd
import sweetviz as sv

marketcp_data = pd.read_csv('/content/marketing_campaign.csv', sep='\\t')

# Tạo báo cáo tổng quát cho biến mục tiêu "Response"
report_with_target = sv.analyze(marketcp_data, target_feat='Response')
report_with_target.show_html("Marketing_Campaign_EDA_With_Target_Report.html")
```



Phân phối của biến mục tiêu



Theo phần “*TOP CATEGORIES*” cho biến Response:

- Tổng số quan sát: 2240
- Trong đó:
 - 334 khách hàng phản hồi “Yes” (1) → chiếm 15%
 - 1906 khách hàng không phản hồi “No” (0) → chiếm 85%

Như vậy, phần lớn khách hàng không phản hồi chiến dịch marketing, tập dữ liệu mất cân bằng.

Mức độ liên hệ các biến khác:

CATEGORICAL ASSOCIATIONS (UNCERTAINTY COEFFICIENT, 0 to 1)		THESE FEATURES GIVE INFORMATION ON Response:		NUMERICAL ASSOCIATIONS (CORRELATION RATIO, 0 to 1)	
Response PROVIDES INFORMATION ON...				Response CORRELATION RATIO WITH...	
Z_CostContact	1.00	AcceptedCmp5	0.09	MntWines	0.25
Z_Revenue	1.00	AcceptedCmp1	0.07	MntMeatProducts	0.24
AcceptedCmp5	0.14	AcceptedCmp3	0.06	NumCatalogPurchases	0.22
AcceptedCmp2	0.13	Teenhome	0.03	Recency	0.20
AcceptedCmp1	0.13	AcceptedCmp4	0.03	NumWebPurchases	0.15
AcceptedCmp3	0.09	Marital_Status	0.03	MntGoldProds	0.14
AcceptedCmp4	0.05	AcceptedCmp2	0.02	Income	0.14
Teenhome	0.02	Education	0.01	MntFruits	0.13
Marital_Status	0.01	Kidhome	0.01	MntSweetProducts	0.12
Kidhome	0.00	Complain	0.00	MntFishProducts	0.11
Education	0.00	Z_CostContact	0.00	NumStorePurchases	0.04
Complain	0.00	Z_Revenue	0.00	ID	0.02
				Year_Birth	0.02
				NumWebVisitsMonth	0.00

Phần “Associations” cho thấy mức độ liên hệ giữa Response và các biến khác (theo hệ số *Uncertainty Coefficient*, từ 0 đến 1 — càng cao thì mối quan hệ càng mạnh)

B2.3: Báo cáo phân tích so sánh 2 subset Khách hàng có trẻ nhỏ và khách hàng không có trẻ nhỏ.


```
import pandas as pd
import sweetviz as sv

marketcp_data = pd.read_csv('/content/marketing_campaign.csv', sep='\\t')

# Tạo báo cáo so sánh 2 nhóm khách hàng: khách hàng có trẻ nhỏ và khách hàng không có trẻ nhỏ

df_has_kids = marketcp_data[marketcp_data["Kidhome"]>0]
df_no_kids = marketcp_data[marketcp_data["Kidhome"]==0]

# So sánh report_comp = sv.compare([df_has_kids, "HasKids"], [df_no_kids, "NoKids"])
report_comp.show_html("sweetviz_compare_kids.html")
```



Màu cam: nhóm khách hàng không có trẻ nhỏ

Màu xanh: nhóm khách hàng có trẻ nhỏ.

Các tính toán thống kê đã được chia theo 2 nhóm khác nhau.

- 947 khách hàng có trẻ nhỏ
- 1293 khách hàng không có trẻ nhỏ

Bài tập thực hành 2: Tìm hiểu các tính năng và cách sử dụng sản phẩm AutoViz áp dụng trên tập dữ liệu Marketing Campaign

- **B1: Cài đặt thư viện autoviz**
- **B2: Sử dụng autoviz cho tập dữ liệu marketing_campaign.csv.**

B2.1: Báo cáo từ file với định dạng biểu đồ là svg

```
import pandas as pd
from autoviz.AutoViz_Class import AutoViz_Class

# Khởi tạo AutoViz
AV = AutoViz_Class()

# Load dữ liệu
marketing_data =
pd.read_csv("/content/marketing_campaign.csv", sep="\t")

# Tạo visualization tự động từ file
filename = "marketing_campaign.csv"
# depVar = biến mục tiêu nếu bạn có (nếu không để '')
dft = AV.AutoViz(
    filename,
    sep='\t',
    depVar='', # để '' nếu không có target
    dfte=None,
    header=0,
    verbose=2,
    lowess=False,
    chart_format='svg', # hoặc 'png'
    max_rows_analyzed=50000,
    max_cols_analyzed=50
)
# AutoViz sẽ in logs và mở/ghi hàng loạt hình ảnh / báo cáo
```

```

Imported v0.1.905. Please call AutoViz in this sequence:
AV = AutoViz_Class()
%matplotlib inline
dfte = AV.AutoViz(filename, sep=',', depVar='', dfte=None, header=0, verbose=1, lowess=False,
                  chart_format='svg',max_rows_analyzed=15000,max_cols_analyzed=30, save_plot_dir=None)
Shape of your Data Set loaded: (2240, 29)
#####
##### C L A S S I F Y I N G   V A R I A B L E S #####
#####
Classifying variables in data set...
Printing up to 30 columns (max) in each category:
Numeric Columns : ['Income']
Integer-Categorical Columns: ['Year_Birth', 'Kidhome', 'Teenhome', 'Recency', 'MntWines', 'MntFruits', 'MntMeatProducts', 'MntFishProducts', 'MntGoldProducts', 'NumDealsPurchases', 'NumWebPurchases', 'NumCatalogPurchases', 'NumStorePurchases', 'NumWebVisitsMonth', 'AcceptedCmp3', 'AcceptedCmp4', 'AcceptedCmp5', 'AcceptedCmp1', 'AcceptedCmp2', 'Complain', 'Response']
String-Categorical Columns: ['Education', 'Marital_Status']
Factor-Categorical Columns: []
String-Boolean Columns: []
Numeric-Boolean Columns: ['AcceptedCmp3', 'AcceptedCmp4', 'AcceptedCmp5', 'AcceptedCmp1', 'AcceptedCmp2', 'Complain', 'Response']
Discrete String Columns: ['Dt_Customer']
NLP text Columns: []
Date Time Columns: []
ID Columns: ['ID']
Columns that will not be considered in modeling: ['Z_CostContact', 'Z_Revenue']
29 Predictors classified...
3 variable(s) removed since they were ID or low-information variables
List of variables removed: ['ID', 'Z_CostContact', 'Z_Revenue']

...
Target variable %s
.
.
To fix these data quality issues in the dataset, import FixDQ from autoviz...
All variables classified into correct types.
Output is truncated. View as a scrollable element or open in a text editor. Adjust cell output settings...

```

	Data Type	Missing Values%	Unique Values%	Minimum Value	Maximum Value	DQ Issue
ID	int64	0.000000	100	0.000000	11191.000000	Possible ID column: drop before modeling step
Year_Birth	int64	0.000000	2	1893.000000	1996.000000	Column has 3 outliers greater than upper bound (2004.00) or lower than lower bound(1932.00). Cap them or remove them
Education	object	0.000000	0			No issue
Marital_Status	object	0.000000	0			3 rare categories: ['Alone', 'Absurd', 'YOLO']. Group them into a single category or drop the categories
Income	float64	1.071429	NA	1730.000000	66666.000000	24 missing values. Impute them with mean, median, mode, or a constant value such as 123. Column has 8 outliers greater than upper bound (118350.50) or lower than lower bound(-14525.50). Cap them or remove them
Kidhome	int64	0.000000	0	0.000000	2.000000	No issue
Teenhome	int64	0.000000	0	0.000000	2.000000	No issue
Dt_Customer	object	0.000000	29			Possible high cardinality column with 683 unique values. Use hash encoding or text embedding to reduce dimension
Recency	int64	0.000000	4	0.000000	99.000000	No issue
MntWines	int64	0.000000	34	0.000000	1493.000000	Column has 35 outliers greater than upper bound (1225.00) or lower than lower bound(-697.00). Cap them or remove them
MntFruits	int64	0.000000	7	0.000000	199.000000	Column has 227 outliers greater than upper bound (81.00) or lower than lower bound(-47.00). Cap them or remove them
MntMeatProducts	int64	0.000000	24	0.000000	1725.000000	Column has 175 outliers greater than upper bound (556.00) or lower than lower bound(-308.00). Cap them or remove them
MntFishProducts	int64	0.000000	8	0.000000	259.000000	Column has 223 outliers greater than upper bound (120.50) or lower than lower bound(-67.50). Cap them or remove them
MntGoldProducts	int64	0.000000	7	0.000000	263.000000	Column has 243 outliers greater than upper bound (81.00) or lower than lower bound(-47.00). Cap them or remove them
NumDealsPurchases	int64	0.000000	9	0.000000	362.000000	Column has 207 outliers greater than upper bound (126.50) or lower than lower bound(-61.50). Cap them or remove them
NumWebPurchases	int64	0.000000	0	0.000000	15.000000	Column has 86 outliers greater than upper bound (6.00) or lower than lower bound(-2.00). Cap them or remove them
NumCatalogPurchases	int64	0.000000	0	0.000000	27.000000	Column has 4 outliers greater than upper bound (12.00) or lower than lower bound(-6.00). Cap them or remove them
NumStorePurchases	int64	0.000000	0	0.000000	13.000000	Column has 23 outliers greater than upper bound (10.00) or lower than lower bound(-6.00). Cap them or remove them
NumWebVisitsMonth	int64	0.000000	0	0.000000	20.000000	No issue
AcceptedCmp3	int64	0.000000	0	0.000000	1.000000	Column has 8 outliers greater than upper bound (13.00) or lower than lower bound(-3.00). Cap them or remove them
AcceptedCmp4	int64	0.000000	0	0.000000	1.000000	No issue
AcceptedCmp5	int64	0.000000	0	0.000000	1.000000	No issue
AcceptedCmp1	int64	0.000000	0	0.000000	1.000000	No issue
AcceptedCmp2	int64	0.000000	0	0.000000	1.000000	No issue
Complain	int64	0.000000	0	0.000000	1.000000	No issue
Z_CostContact	int64	0.000000	0	3.000000	3.000000	Possible Zero-variance or low information column: drop before modeling step
Z_Revenue	int64	0.000000	0	11.000000	11.000000	Possible Zero-variance or low information column: drop before modeling step
Response	int64	0.000000	0	0.000000	1.000000	No issue

B2.2: Báo cáo phân tích, tương quan biến mục tiêu “Response”.

```

# Với nhiều tùy chọn hơn
dft_advanced = AV.AutoViz(
    filename="",
    dfte=marketing_data,
    depVar="Response",
    verbose=2, # 0: ít thông tin, 1: trung bình, 2: chi tiết
    lowess=False, # Thêm đường xu hướng LOWESS

```

```

        chart_format="bokeh", # "png", "svg", "bokeh",
        "server", "html"
        max_rows_analyzed=150000, # Số dòng tối đa phân
tích
        max_cols_analyzed=30 # Số cột tối đa phân tích
    )

```

```


Shape of your Data Set loaded: (2240, 29)
#####
##### CLASSIFYING VARIABLES #####
#####
Classifying variables in data set...
Printing up to 30 columns (max) in each category:
Numeric Columns: ['Income']
Integer-Categorical Columns: ['Year_Birth', 'Kidhome', 'Teenhome', 'Recency', 'MntWines', 'MntFruits', 'MntMeatProducts', 'MntFishProducts', 'MntSweetProducts', 'MntG
String-Categorical Columns: ['Education', 'Marital_Status']
Factor-Categorical Columns: []
String-Boolean Columns: []
Numeric-Boolean Columns: ['AcceptedCmp3', 'AcceptedCmp4', 'AcceptedCmp5', 'AcceptedCmp1', 'AcceptedCmp2', 'Complain']
Discrete String Columns: ['Dt_Customer']
MLP text Columns: []
Date Time Columns: []
ID Columns: ['ID']
Columns that will not be considered in modeling: ['Z_CostContact', 'Z_Revenue']
28 Predictors classified...
3 variable(s) removed since they were ID or low-information variables
List of variables removed: ['ID', 'Z_CostContact', 'Z_Revenue']

##### Binary_Classification problem #####
Columns to delete:
" ['Z_CostContact', 'Z_Revenue']"
Boolean variables %s
...
ID variables %s
" ['ID']"
Target variable %s
' Response'

Output is truncated. View as a scrollable element or open in a text editor. Adjust cell output settings...


```

Dataframe: 2240 hàng × 29 cột




Nhận xét biểu đồ Scatter :

- Trục x chỉ hai giá trị rời rạc (0 hoặc 1). Điểm dữ liệu tập trung thành hai cột dọc tại 0 và 1.
- Trục y (Income) rất lệch phải, có một số điểm cực lớn (outlier rõ rệt $\sim 7e5$ trên ảnh).
- Phần lớn điểm nằm gần phía dưới trục y (gần 0), gây chùng lấn mạnh.



Nhận xét biểu đồ histogram:


- Biểu đồ stacked bar hiển thị counts của Response=0 (màu xanh) và Response=1 (màu cam) cho từng mức Education (Basic, 2n Cycle, Graduation, Master, PhD).
- Graduation là nhóm lớn nhất về số lượng cá nhân; các nhóm khác nhỏ hơn.



KDE plot is erroring due to problems with DynamicMaps. Hence it is skipped


Nhận xét biểu đồ KDE:

- Màn hình hiển thị 2 đường KDE: màu xanh cho Element=0, màu đỏ cho Element=1.
- Red (class 1) có một đỉnh rất cao và hẹp gần 0; blue (class 0) phân bố rộng hơn và thấp hơn.
- X-axis trên ảnh chạy từ âm vài trăm tới vài ngàn; điều này mâu thuẫn với scatter (nơi Income có giá trị lớn tới $\sim 7e5$) — có dấu hiệu inconsistency/cần kiểm tra.



Nhận xét biểu đồ Violin

- Hai violin hiển thị dạng “sao chép” (mirror) cho mỗi lớp Response. Cả hai đều có phần thân chính tập trung quanh trục giữa (gần 0) và hai đuôi kéo dài hai bên.
- Trục y trên ảnh có giá trị âm → dương, không giống scale trực tiếp của Income (thường ≥ 0). Điều này rất có khả năng AutoViz đã chuẩn hóa/scale (z-score) các biến trước khi vẽ violin, nên bạn đang nhìn phân bố đã chuẩn hóa chứ không phải giá trị gốc.
- So sánh: Violin cho Response = 1 có vẻ hẹp hơn / tập trung hơn (ít biến thiên) hoặc hơi lệch so với Response = 0



Nhận xét biểu đồ heatmap:

- Có các block tương quan dương mạnh giữa các biến Mnt* (MntWines, MntMeatProducts, MntFishProducts, MntSweetProducts, ...) — nghĩa là các mức chi tiêu cho các loại sản phẩm có xu hướng tăng cùng nhau.
- Một vài cặp Num*Purchases cũng tương quan khá cao với nhau (ví dụ: NumStorePurchases ↔ NumCatalogPurchases hoặc ↔ NumWebPurchases).
- Year_Birth và có thể Age (nếu có) thường sẽ tương quan âm với Year_Birth — heatmap có thể hiện điều này (nếu Age không tồn tại, Year_Birth có thể tương quan với Income theo 1 chiều).
- Giá trị tương quan với Response (target) có vẻ không quá cao — tức không có một biến numeric đơn lẻ có correlation mạnh với Response.

