

Titanic - Machine Learning from Disaster

Phạm Ngọc Phương Uyên, Trần Thu Hiền, Nguyễn Châu Nhật Tường

Đại học Sài Gòn

Tóm tắt

Dự đoán khả năng sống sót của hành khách sau thảm họa Titanic là một bài toán kinh điển trong lĩnh vực học máy, mang lại nhiều giá trị trong nghiên cứu mô hình phân loại, trích chọn đặc trưng và phân tích dữ liệu con người.

Trong nghiên cứu này, chúng tôi đề xuất một mô hình **ensemble learning** (học kết hợp) được cải tiến, tích hợp nhiều thuật toán như **Logistic Regression, Decision Tree, Random Forest, Gradient Boosting, XGBoost, SVM, KNN, Naive Bayes** nhằm nâng cao độ chính xác và khả năng diễn giải của kết quả dự đoán.

Mô hình đề xuất sử dụng các kỹ thuật tiền xử lý nâng cao, bao gồm chuẩn hóa đặc trưng, mã hóa dữ liệu phân loại và xử lý giá trị khuyết thiếu, kết hợp với **phân tích tầm quan trọng của đặc trưng** để xác định các yếu tố ảnh hưởng mạnh nhất đến khả năng sống sót, chẳng hạn như **giới tính, độ tuổi và hạng vé của hành khách**..

Kết quả thực nghiệm trên bộ dữ liệu **Titanic** cho thấy mô hình Gradient Boosting là lựa chọn vượt trội so với các mô hình khác sau khi chúng tôi kiểm tra nhiều mô hình

Nghiên cứu này không chỉ khẳng định tính hiệu quả của học máy trong phân tích dữ liệu lịch sử mà còn mở ra hướng ứng dụng tiềm năng cho các bài toán **dự báo rủi ro và ra quyết định dựa trên dữ liệu** trong các lĩnh vực thực tiễn khác.

Từ khóa: Titanic, Học máy, Ensemble Learning, Tiền xử lý dữ liệu, Phân loại, Mô hình dự đoán.

1. GIỚI THIỆU

Trong lĩnh vực khoa học dữ liệu, việc dự đoán kết quả dựa trên dữ liệu lịch sử là một trong những hướng nghiên cứu nền tảng, đóng vai trò quan trọng trong nhiều ứng dụng thực tiễn như dự báo rủi ro, ra quyết định và phân tích hành vi con người. Bài toán **Titanic – Machine Learning from Disaster** là một ví dụ kinh điển, cung cấp môi trường thử nghiệm

tiêu chuẩn để đánh giá năng lực của các mô hình học máy trong việc **phân loại nhị phân** (sống sót hoặc không sống sót) dựa trên đặc trưng cá nhân của hành khách.

Mặc dù bài toán này đã được nhiều nghiên cứu và cộng đồng Kaggle khai thác, song việc **xử lý dữ liệu thiếu, chọn đặc trưng phù hợp và xây dựng mô hình tối ưu** vẫn là những thách thức quan trọng. Các phương pháp truyền thống như hồi quy logistic hay cây quyết định đơn lẻ thường đạt hiệu năng trung bình do **chưa khai thác được mối quan hệ phi tuyến và sự tương tác giữa các biến** như giới tính, tuổi, hạng vé hay vị trí lên tàu. Ngoài ra, sự mất cân bằng dữ liệu và các biến liên tục có độ lệch cao (như giá vé, độ tuổi) cũng ảnh hưởng đáng kể đến độ chính xác của mô hình.

Để giải quyết các hạn chế trên, nghiên cứu này đề xuất **một mô hình học kết hợp (Ensemble Learning)** tích hợp sức mạnh của nhiều thuật toán, bao gồm **Logistic Regression, Decision Tree, Random Forest, Gradient Boosting, XGBoost, SVM, KNN, Naive Bayes**. Cách tiếp cận này cho phép tận dụng ưu điểm riêng của từng mô hình: khả năng tổng quát hóa tốt, khả năng xử lý dữ liệu phi tuyến và ổn định trước nhiễu. Song song đó, chúng tôi áp dụng các kỹ thuật tiền xử lý như xử lý giá trị thiếu, xử lý đặc trưng, phân tích dữ liệu, mã hóa, chuẩn hóa biến số

Bằng cách kết hợp giữa xử lý dữ liệu có hệ thống và mô hình học kết hợp tối ưu, nghiên cứu này hướng tới việc tăng độ chính xác dự đoán, đồng thời làm rõ các yếu tố quan trọng ảnh hưởng đến khả năng sống sót của hành khách. Mục tiêu cuối cùng là chứng minh rằng việc áp dụng đúng quy trình phân tích và kết hợp mô hình có thể giúp biến một bài toán cổ điển thành một ví dụ tiêu biểu về ứng dụng học máy trong dự báo rủi ro thực tế.

II. PHƯƠNG PHÁP ĐỀ XUẤT

2.1 Các phương pháp Machine Learning đã được áp dụng

Bộ dữ liệu Titanic được nghiên cứu rộng rãi trong cộng đồng học máy, đặc biệt qua các cuộc thi Kaggle. Các thuật toán được áp dụng bao gồm:

- Cây quyết định và Rừng ngẫu nhiên: Hiệu quả trong xử lý dữ liệu hỗn hợp và nắm bắt mối quan hệ phi tuyến.
- Máy vector hỗ trợ: Hiệu suất mạnh mẽ với lựa chọn kernel phù hợp.
- Gradient Boosting: XGBoost và LightGBM cho thấy hiệu suất vượt trội trong nhiều cuộc thi.

- Mạng nơ-ron: Các phương pháp học sâu được khám phá, nhưng kết quả hỗn hợp trên bộ dữ liệu nhỏ.

2.2 Các chiến lược Feature Engineering phổ biến

Nghiên cứu cho thấy kỹ thuật đặc trưng (feature engineering) ảnh hưởng đáng kể đến hiệu suất mô hình. Các đặc trưng phổ biến được tạo ra bao gồm:

- Trích xuất danh xưng từ tên hành khách (Mr., Mrs., Miss, Master,...).
- Tính toán kích thước gia đình bằng cách kết hợp anh chị em, vợ/chồng, cha mẹ và con cái.
- Thông tin boong tàu từ số cabin.
- Phân loại giá vé thành các nhóm (bins) để rời rạc hóa giá trị liên tục.
- Nhóm tuổi để nắm bắt tác động của giai đoạn cuộc sống.

2.3. Tổng quan vấn đề

Bộ dữ liệu Titanic – Machine Learning from Disaster bao gồm thông tin chi tiết của hơn 891 hành khách trên con tàu RMS Titanic và 12 đặc trưng (cột) được mô tả thông qua các biến nhân khẩu học và xã hội học như tuổi (Age), giới tính (Sex), hạng vé (Pclass), giá vé (Fare), số người thân đi cùng (SibSp, Parch), cảng lên tàu (Embarked),... cùng nhãn đầu ra Survived (1: sống sót, 0: không sống sót)

Mục tiêu của bài toán là **phân loại nhị phân** từng hành khách vào hai nhóm sống sót hoặc không sống sót dựa trên các đặc trưng đầu vào

Tuy nhiên, dữ liệu Titanic tồn tại nhiều vấn đề thực tế của dữ liệu thô:

- Một số đặc trưng có **giá trị bị thiếu** (Age, Cabin, Embarked).
- Phân bố dữ liệu không đồng đều và **có độ lệch cao** (Fare, Age).
- Sự chồng chéo giữa các biến định tính (ví dụ: Title từ Name liên quan chặt với Sex và Age).

Những yếu tố này gây ảnh hưởng trực tiếp đến chất lượng huấn luyện mô hình. Do đó, việc xây dựng một quy trình tiền xử lý chặt chẽ, kết hợp với mô hình học kết hợp (ensemble) có khả năng khái quát tốt, là cần thiết để đảm bảo kết quả dự đoán chính xác và ổn định.

2.4 Mô hình đề xuất

Bốn giai đoạn chính:

1. Trích chọn và mã hóa đặc trưng (Feature Engineering & Encoding)
 - Phân tích tên (Name) và phân tích danh xưng (Title)
 - Phân tích Gia đình (FamilySize) và Đi một mình (IsAlone)
 - Phân tích Cabin Deck
 - Tách lại tập dữ liệu sau khi thêm các cột FE
2. Tiền xử lý dữ liệu (Data Preprocessing)
 - Xử lý missing values (chỉ fit trên train để tránh leakage)
 - Mã hóa biến categorical
 - Chuẩn hóa biến số (scale Age và Fare để mô hình như Logistic Regression hoạt động tốt)
 - Tách x và y cho train (test không có y)
3. Huấn luyện mô hình học kết hợp (Ensemble Learning)
 - Logistic Regression
 - Decision Tree,
 - Random Forest
 - Gradient Boosting
 - XGBoost
 - SVM
 - KNN
 - Naive Bayes
4. Đánh giá và phân tích kết quả (Evaluation & Validation)
 - So sánh và lựa chọn mô hình tốt hơn cho dự đoán

2.5 Chi tiết triển khai

- Thực hiện trong môi trường Python với các thư viện Pandas, NumPy, Scikit-learn, Seaborn, Matplotlib
- Phân tích dữ liệu thiếu (missing data) và nhận xét, đề xuất xử lý

- Phân tích đơn biến (univariate analysis)
- Phân tích hai biến (bivariate analysis)
- Tiền xử lý dữ liệu (data preprocessing)
- Xây dựng và huấn luyện mô hình
- Hyperparameter tuning
- Dự đoán trên test set và tạo tập
- Tạo báo cáo tổng kết

III. THÍ NGHIỆM VÀ KẾT QUẢ

3.1 Thiết lập thí nghiệm

Dữ liệu

Bộ dữ liệu Titanic – Machine Learning from Disaster được công bố trên nền tảng Kaggle, gồm hai tập chính:

- Train set: 891 mẫu có gán nhãn Survived (1 hoặc 0).
- Test set: 418 mẫu chưa gán nhãn, dùng để kiểm tra khả năng tổng quát của mô hình.


Các biến đầu vào bao gồm cả định lượng (Age, Fare, FamilySize) và định tính (Sex, Pclass, Embarked, Title, Cabin_Deck)..

Quá trình toàn bộ các bước thực hiện và kết quả




Trước khi huấn luyện mô hình, dữ liệu được khảo sát bằng các kỹ thuật phân tích trực quan nhằm đánh giá chất lượng và đặc trưng phân bố.

Trực quan hóa dữ liệu thiếu




Biến Cabin và Age có tỷ lệ thiếu cao nhất (trên 20%), trong khi Fare chỉ thiếu 1 giá trị trong tập kiểm tra. Các giá trị thiếu được xử lý bằng cách điền trung vị (median)

Phân tích đơn biến Survival



Tỷ lệ sống sót tổng thể: chỉ khoảng 38.4% hành khách sống sót, trong khi 61.6% tử vong. Đây là dấu hiệu của mất cân bằng nhãn (class imbalance), cần chú ý khi huấn luyện mô hình

Phân tích hai biến




Phụ nữ (female) có tỷ lệ sống sót cao hơn rõ rệt so với nam giới.

Hành khách hạng 1 có cơ hội sống sót cao nhất, trong khi hạng 3 thấp nhất.


Những người đi cùng gia đình (Parch, SibSp > 0) có tỷ lệ sống sót cao hơn người đi một mình (IsAlone = 1).

Những kết quả này phản ánh đúng nguyên tắc “phụ nữ và trẻ em được ưu tiên cứu trước”.

Phân tích tương tác Pclass & Sex & Survived




Ma trận tương quan



Ma trận tương quan giúp nhận diện các đặc trưng có khả năng trùng lặp thông tin và hỗ trợ việc lựa chọn biến đầu vào cho mô hình.


3.2 Kết quả và phân tích



Mô hình Gradient Boosting đạt hiệu suất cao nhất với độ chính xác trung bình khoảng 83,41% thông qua hương pháp kiểm định chéo (cross-validation), vượt trội so với các mô hình còn lại.

Hai mô hình có độ chính xác tiếp theo là SVM (82,7%) và XGBoost (82,24%), trong khi Naive Bayes (77,78%) và Decision Tree (78,23%) đạt kết quả thấp hơn đáng kể.


Ngoài ra, qua biểu đồ hộp thể hiện phân bố điểm kiểm định, mô hình Gradient Boosting thể hiện độ ổn định cao với phương sai nhỏ, ít giá trị ngoại lai, cho thấy mô hình duy trì hiệu suất tốt và đáng tin cậy trên các tập dữ liệu khác nhau..



Biểu đồ phân bố xác suất sống sót cho thấy mô hình phân biệt rõ ràng hai nhóm hành khách: nhóm có xác suất sống sót rất thấp (gần 0) và nhóm có xác suất cao (gần 1). Ranh giới phân loại tại ngưỡng 0.5 được xác định rõ ràng, chứng tỏ mô hình có mức độ tự tin cao khi đưa ra dự đoán.

Khi xem xét phân bố xác suất theo từng kết quả dự đoán, nhóm hành khách được dự đoán “chết” tập trung mạnh ở vùng xác suất thấp (<0.2), trong khi nhóm “sống sót” tập trung ở vùng xác suất cao (>0.8). Điều này chứng minh khả năng phân tách xác suất hiệu quả và độ tin cậy cao của mô hình Gradient Boosting.

3.3 Đánh giá trực quan




Độ quan trọng của các đặc trưng (feature importance) trong mô hình Gradient Boosting, kết quả cho thấy “Title” (danh xưng của hành khách) là yếu tố có mức ảnh hưởng cao nhất, chiếm hơn 50% tổng mức độ quan trọng.

Đặc trưng này phản ánh đồng thời giới tính, độ tuổi và địa vị xã hội – những yếu tố có liên quan mật thiết đến khả năng sống sót trong thảm họa Titanic.

Theo sau đó, các đặc trưng “Fare” (giá vé) và “Pclass” (hạng vé) cũng có vai trò đáng kể, thể hiện mối liên hệ giữa điều kiện kinh tế – tầng lớp xã hội và cơ hội được cứu sống

Bên cạnh đó, các yếu tố như “Age” (tuổi), “FamilySize” (quy mô gia đình), “Has_Cabin” (có thông tin cabin) và “Sex” (giới tính) cũng đóng góp giá trị cho mô hình, phản ánh các khía cạnh nhân khẩu học và xã hội học của hành khách.

Cụ thể, các nhóm phụ nữ, trẻ em và hành khách thuộc tầng lớp cao hơn có xác suất sống sót cao hơn, phù hợp với quy tắc “**Women and children first**” được ghi nhận trong lịch sử vụ đắm tàu.



Ma trận nhầm lẫn trên tập huấn luyện cho thấy mô hình dự đoán chính xác 528/549 trường hợp tử vong (96,2%) và 290/342 trường hợp sống sót (84,8%). Sai số chủ yếu đến từ 52 trường hợp sống sót bị dự đoán nhầm là tử vong

Phân bố kết quả trên tập kiểm thử cũng thể hiện rằng mô hình dự đoán 268 hành khách tử vong và 150 hành khách sống sót, tỷ lệ này tương đối tương đồng với phân bố thực tế trong dữ liệu Titanic. Điều đó cho thấy mô hình không bị lệch lớp (class imbalance) và có khả năng tổng quát hóa tốt khi áp dụng lên dữ liệu mới

IV. KẾT LUẬN

Trong nghiên cứu này, chúng tôi đã tiến hành xây dựng, huấn luyện và đánh giá một loạt các mô hình học máy nhằm dự đoán khả năng sống sót của hành khách trên con tàu Titanic. Bài toán này không chỉ là một ví dụ kinh điển trong lĩnh vực học máy mà còn thể hiện rõ tầm quan trọng của việc kết hợp giữa kỹ thuật xử lý dữ liệu, trích chọn đặc trưng và lựa chọn mô hình phù hợp trong các bài toán phân loại nhị phân thực tế.

Trên cơ sở bộ dữ liệu Titanic do Kaggle cung cấp, chúng tôi đã áp dụng quy trình tiền xử lý dữ liệu chặt chẽ, bao gồm: xử lý giá trị khuyết thiếu, mã hóa các biến phân loại, chuẩn hóa các biến số và đặc biệt là xây dựng các đặc trưng mới có ý nghĩa thực tiễn

như *Title*, *FamilySize*, *IsAlone* và *Cabin_Deck*. Các đặc trưng này giúp mô hình khai thác tốt hơn mối quan hệ giữa nhân khẩu học, tầng lớp xã hội và hành vi sinh tồn của hành khách. Việc kết hợp giữa tiền xử lý dữ liệu và trích chọn đặc trưng hợp lý đã góp phần đáng kể vào việc cải thiện chất lượng đầu vào cho mô hình học máy.

Chúng tôi đã tiến hành thử nghiệm với nhiều thuật toán khác nhau như Logistic Regression, Decision Tree, Random Forest, Gradient Boosting, XGBoost, SVM, KNN và Naive Bayes, trong đó Gradient Boosting cho kết quả tốt nhất với độ chính xác trung bình đạt 83,41%, thể hiện sự vượt trội về khả năng khái quát hóa và ổn định so với các mô hình còn lại. Mô hình này không chỉ thể hiện khả năng phân biệt rõ ràng giữa hai nhóm hành khách sống sót và tử vong mà còn cho thấy độ tin cậy cao thông qua phân bố xác suất dự đoán rõ ràng và phương sai thấp trong kiểm định chéo.

Phân tích độ quan trọng của các đặc trưng cho thấy “Title” (danh xưng) là yếu tố có ảnh hưởng lớn nhất đến khả năng sống sót, phản ánh đồng thời giới tính, độ tuổi và vị thế xã hội của hành khách. Tiếp theo là “Fare” (giá vé) và “Pclass” (hạng vé) – hai đặc trưng thể hiện mối quan hệ giữa điều kiện kinh tế và cơ hội được cứu sống. Những kết quả này hoàn toàn phù hợp với dữ kiện lịch sử được ghi nhận rằng “phụ nữ và trẻ em được ưu tiên trước” trong quá trình sơ tán của vụ đắm tàu Titanic.

Từ kết quả đạt được, có thể khẳng định rằng việc kết hợp nhiều mô hình học máy trong khuôn khổ Ensemble Learning cùng với quy trình tiền xử lý dữ liệu khoa học và hệ thống trích chọn đặc trưng phù hợp giúp cải thiện đáng kể hiệu quả dự đoán và độ tin cậy của mô hình. Nghiên cứu này không chỉ góp phần minh chứng cho tính ứng dụng mạnh mẽ của học máy trong việc phân tích dữ liệu lịch sử mà còn mở ra khả năng ứng dụng cho nhiều bài toán dự báo rủi ro trong thực tiễn như y học, tài chính hay giao thông vận tải.